

一、任务背景与目标

本次培训要求在提供的 RM2025 小车数据集上，以 **YOLO26n** 为 baseline 训练一个目标检测模型。过程中需要在 AI 辅助下理解训练流程、损失函数与相关算法，并不断调整训练策略，在验证集上评估模型效果。

二、数据集与划分

- **素材**：作业提供的 CodeBase (ultralytics-YOLO26) 与标注数据。
- **已标注**：1511 张图、1511 个标签，单类别 `car`，共 6855 个标注框。
- **未标注**：302 张（可选补全,但经过尝试与评估，发现加上这组照片后，精确度没有很大提升，但 R，mAP 值略微下降，未并入新训练集的模型 mAP50，R 值略微更高，而且训练更方便，就没补全）。
- **格式**：标准 YOLO 格式，每行 `class cx cy w h`（归一化坐标）。
- **划分**：随机按 8:1:1 分 train/val/test（随机种子 0），初始 train 1208 / val 151 / test 152。
- **数据配置** `data.yaml`: `names: {0: car}`。
- **未标注补全（可选）**：用训练好的模型对 302 张做**伪标注**，再在 LabelImg 中人工修正，最后并入训练集，使 train 扩充到 1509 张。

三、训练步骤（原理）

一个 epoch（把训练集完整过一遍）的流程：

1. **前向传播**：图像经网络得到预测框与类别。
2. **计算损失**：比较预测与真值，得到 box / cls / dfl 等损失。
3. **反向传播**：自动求导算出各参数梯度。
4. **优化器更新**：按学习率更新权重。
5. **清零梯度**：为下一批做准备。

- 6. 验证：在验证集计算 mAP 等指标。
- 7. 学习率调度 & 保存：调整学习率，保存最佳权重。

训练中还涉及：AMP 混合精度（省显存提速）、梯度累积、学习率 warmup、EMA 指数滑动平均、数据增强、mAP 计算与最佳权重选择、早停与断点续训。

四、损失函数

YOLO26 目标检测的总损失由三部分加权组成，优化目标约为 $7.5 \cdot \text{box} + 0.5 \cdot \text{cls} + 1.5 \cdot \text{dfl}$ （权重见 args.yaml）：

损失	作用	说明
cls（分类损失）	判断每个框的类别	BCE（二值交叉熵），每类独立计算
box（框回归损失）	让预测框贴近真值框	CloU，综合考虑重叠度、中心距离、长宽比
dfl / l1（定位分布损失）	提升边界定位精度	DFL（分布焦点损失）；YOLO26 亦采用 L1 形式

五、不同无监督算法的区别

方法	学习目标	代表	特点
聚类	把数据分组	K-means	不学表征，依赖距离度量
重构 / 自编码	重建输入	AE / VAE / MAE	学压缩表征，易学到细节
对比学习	拉近正样本、推远负样本	SimCLR / MoCo	需要负样本，表征质量高
自蒸馏 / 预测	预测目标的表征	BYOL / DINO / JEPA	不需负样本，需防止表示塌缩
生成式	建模数据分布	GAN / 扩散模型	生成质量高，训练较难

六、实验与调参（训练表格）

在验证集（151 张）上对比多组实验。控制变量：一次只改一个因素。

序号	模型	训练数据	imgsz	batch	epochs	mAP50	mAP50-95	P	R	备注
1	yolo26n	1208	640	16	20	0.908	0.576	0.900	0.807	baseline
2	yolo26n	1208	640	16	50	0.945	0.621	0.926	0.893	增加轮数
3	yolo26n	1208	960	16	50	0.959	0.650	0.956	0.930	增大输入(综合最佳)
4	yolo26n	1208	1280	8	20	0.935	0.625	0.918	0.865	大输入但轮数少
5	yolo26n	1208	1280	8	50	0.958	0.657	0.957	0.897	定位最佳
6	yolo26n	1509	960	16	50	0.957	0.648	0.962	0.915	伪标注扩数据

关键结论（消融）：

- 轮数 20→50：整体指标明显提升（mAP50 +0.037）。
- imgsz 640→960/1280：主要提升 mAP50-95（定位更准）。
- 伪标注扩数据（1208→1509）：基本持平（同质数据 + 少量噪声）。
- mAP50 先达到平台，mAP50-95 后达到平台 → “找到”较易，“框准”较难。

测试集（test，152 张）成绩

该测试集在划分后留出、未参与任何调参，仅用于最终评估，因此更能反映真实泛化能力。

序号	模型	imgsz	epochs	训练数据	mAP50	mAP50-95	P	R
1	yolo26n	640	20	1208	0.913	0.592	0.912	0.873

2	yolo26n	640	50	1208	0.936	0.615	0.946	0.905
3	yolo26n	960	50	1208	0.954	0.651	0.964	0.920
4	yolo26n	1280	20	1208	0.944	0.645	0.947	0.901
5	yolo26n	1280	50	1208	0.949	0.659	0.948	0.920
6	yolo26n	960	50	1509	0.952	0.653	0.966	0.930

验证集 vs 测试集（以最终选定的 960/50 为例）：验证集 mAP50=0.959、测试集 mAP50=0.954；验证集 mAP50-95=0.650、测试集 mAP50-95=0.651 —— 两者几乎一致，说明模型泛化良好、未过拟合验证集。

七、遇到的问题与心得

- 工具链问题**：标注工具 LabelImg 与新版 PyQt5 存在 float→int 兼容问题，光标进入图像即崩溃；定位到 canvas.py 的绘制代码并修正后解决。
- 显存限制**：8GB 显存下，imgsz 1280 只能 batch 8，imgsz 2048 只能 batch 1；更大输入更准但更慢、收益递减。
- 指标理解**：mAP50 看“有没有找到”，mAP50-95 看“框得准不准”；应看**验证集 mAP**而非训练 loss 判断好坏，并留意 val 损失是否回升（过拟合）。
- 伪标注认识**：伪标注能省人力，但若数据同质、且模型来自同一批数据，信息增量有限，需人工修正并谨慎评估。
- 实验方法**：坚持“一次只改一个因素、同一验证集对比”，才能判断改动是否有效。

八、结论

以 YOLO26n 为 baseline，通过增大输入尺寸与训练轮数，验证集 mAP50 从 0.908 提升到约 0.959、mAP50-95 从 0.576 提升到约 0.650；伪标注扩充数据在本数据集上未带来明显提升。综

合选择 $\text{imgsz}=960$ 、50 epochs 的模型作为最终提交权重，其在留出的测试集上取得 $\text{mAP50}=0.954$ 、 $\text{mAP50-95}=0.651$ 。